1. Models de regressió lineal

1.1. Model **general** (mínims quadrats)

$$\begin{aligned} y &= X\beta + \varepsilon \\ &\downarrow y_1 \downarrow & \downarrow x_{11} & \dots & x_{1m} \downarrow \alpha \downarrow \\ &\vdots & \vdots & \ddots & \vdots \\ y_n &= \begin{pmatrix} \vdots & \ddots & \vdots \\ x_{n1} & \dots & x_{nm} \end{pmatrix} \begin{pmatrix} \alpha & \downarrow & \vdots \\ \beta_1 & \downarrow & \vdots \\ \vdots & \ddots & \vdots \\ x_{nm} & \dots & x_{nm} \end{pmatrix} + \begin{pmatrix} \vdots \\ \xi_n \end{pmatrix}$$

- y : Vector de resposta
- X : Matriu de disseny
 - $x_{ij} \in \{0,1\}$
- $x_{i1} = 1$ (intercept) ε : Errors aleatoris (i.i.d.)
 - $\mathbb{E}(\varepsilon) = 0$ $V(\varepsilon) = \sigma^2 I_n$

» Incògnites
$$\beta$$
 \sim

Si $\operatorname{Rang}(X) = m$:

$$\widehat{\beta} = \left[(X^T X)^{-1} X^T y \right]$$

•
$$\mathbb{E}(\widehat{\beta}) = \beta$$

>> Variància de l'error
$$\sigma^2$$
 \vee

• $V(\widehat{\beta}) = \sigma^2 (X^T X)^{-1}$

1.2. Model clàssic

Tenim $\varepsilon \sim N(0, \sigma^2 I)$.

 \Rightarrow Incògnites β \vee

Si
$$\operatorname{Rang}(X) = m$$
:

 $l^T \widehat{\beta} \sim N(l^T \beta, \sigma^2 l^T (X^T X)^{-1} l)$

» Variància de l'error d Si $\operatorname{Rang}(X) = m$:

$$rst_i = rac{r_i}{\widehat{\sigma} \sqrt{1-p_{ii}}} \sim N(0,1)$$

 r_i element del residu $r = Y - \widehat{Y} = (1-P)Y$

$$p_{ii}$$
 element de $P = X(X^TX)^{-1}X^T$

$$|rst_i|>2 \implies$$
 potencial *outlier*

1.3. Model amb errors dependents

Tenim $\varepsilon_i = \rho \, \varepsilon_i + e_i$ amb ρ conegut tal que:

$${f e}(e_i)=0$$

•
$$Var(e_i) = \sigma^2$$

Construir el nou model (clàssic):

$$\begin{bmatrix} y_i^\star = \beta_0(1-\rho) + \beta_1 x_i^\star + e_i \end{bmatrix}$$
 amb
$$\begin{cases} y_i^\star = y_i - \rho \, y_{i-1} \\ x_i^\star = x_i - \rho \, x_{i-1} \end{cases}$$

1.4. Model dels mínims quadrats generalitzat

Tenim $Var(\varepsilon) = \sigma^2 \Sigma = \sigma^2 P^2$ amb Σ conegut.

⊞ Mètode ∨

Construir el nou model (clàssic):

$$\begin{aligned} P^{-1}Y &= P^{-1}X\beta + P^{-1}\varepsilon\\ y^* &= X^*\beta + \varepsilon^* \end{aligned}$$
 *
$$\hat{\beta} = \boxed{(X^T\Sigma^{-1}X)^{-1}X^T\Sigma^{-1}y}$$

2. Bondat d'ajustament

Coeficient de determinació V

$$R^2 = rac{ESS}{TSS} = 1 - rac{RSS}{TSS} \in (0,1)$$

Coefficient de correlació
$$\vee$$

$$V.A.s. \ A, B \ \text{amb mitjanes} \ \mu_A, \mu_B \ \text{i variàncies} \ \sigma_A^2, \sigma_B^2$$

$$\rho_{AB} = \left[\frac{\mathbb{E}((A - \mu_A)(B - \mu_B))}{\sigma_A \ \sigma_B} \right] \in (-1, 1)$$

Coeficient de correlació mostral

Observacions a_1,\ldots,a_n i b_1,\ldots,b_n amb mitjanes mostrals $\overline{a},\overline{b}$, i variàncies mostrals s_a^2,s_b^2

$$r_{AB} = \left[egin{array}{c} \sum_{i=1}^n (a_i - \overline{a})(b_i - \overline{b}) \\ s_a \, s_b \end{array}
ight] \in (-1,1)$$

3. Tests d'hipòtesis

Hipòtesis nul·la $\mathbf{H_0}: l^T \beta = 0$

Rebutjem H_0 si $|T| > t_{1-\frac{\alpha}{2},\,n}$

» Interval de confiança
$$\vee$$

$$IC_{\alpha}(l^T\beta) = \left(l^T\widehat{\beta} \pm t_{1-\frac{\alpha}{2},\,n-m}\,\widehat{\sigma}\,\sqrt{l^T\,(X^TX)^{-1}\,l}\right)$$

>> Test F generalitzat (múltiples coeficients) >>

$$\circ$$
 Hipòtesis nul·la $H_0:L\beta=0$
$$\circ \ \ \mbox{Estadístic de contrast}$$

 $F = \boxed{\frac{(L\widehat{\beta})^T \left(L(X^TX)^{-1} \, L^T\right)^{-1} \left(L\widehat{\beta}\right) \left(n-m\right)}{q \cdot RSS}} \sim F_{q,\,n}$

amb
$$q$$
 nombre de files de L

• Rebutjem H_0 si $F > F_{1-lpha,\,q,\,n}$

4. Observacions influents

» Mesura de la influència

Influència de l'element i-èssim en el model:

$$D_i = \boxed{ \begin{aligned} & (\widehat{\beta} - \widehat{\beta}_{\overline{i}})^T X^T X \left(\widehat{\beta} - \widehat{\beta}_{\overline{i}} \right) \\ & (p+1) \, \widehat{\sigma}^2 \end{aligned}}$$

β̄_i: estimador de β sense la i-èssima observació

$$\redsymbol{//}$$
 Interpretació de D \sim

Observació influent si:

$$\circ \ D_i > 1$$

•
$$D_i > \frac{4}{n}$$

Leverage de la observació i-èssima del model:

element
$$p_{ii}$$
 de $P = X \, (X^T X)^{-1} X^T$

$$\circ \ p_{ii} > rac{2m}{n} \implies \mathsf{possible} \ \mathsf{influència} \ \mathsf{excessiva}$$

5. Estabilització de la variància

Tenim V.A. X amb:

- Ε(X) = μ
- $Var(X) = k h(\mu)$

Construir una nova V.A.:

Y = g(X)

•
$$\operatorname{Var}(Y) \sim k \, h(\mu) \, g'(\mu)^2$$
 (constant)

Transformacions estabilitzants de variància

•
$$g(\mu) = \int \frac{C}{\sqrt{h(\mu)}} d\mu$$

Distribució	Variància	Transformació
Poisson	$\propto \mu$	$g(X) = \sqrt{X} \ (^*)$
Binomial	$\propto \mu (1 - \mu)$	$g(X)=\arcsin(\sqrt{X})$
Exponencial	$\propto \mu^2$	$g(X)=\ln(X)$
desconeguda (Box-Cox)	desconeguda	$g_{\lambda}(x_i) = \begin{cases} \frac{x_i^{\lambda} - 1}{\lambda} & \text{si } \lambda \end{cases}$

(*) Per n petita, podem fer servir $g(X) = \sqrt{X + \frac{3}{8}}$.

Apèndix

- Estimador $\widehat{\alpha}$ no esbiaixat si $\mathbb{E}(\widehat{\alpha}) = \alpha$ • Covariància $\mathrm{Cov}(a,b) = \boxed{\mathrm{E}(ab) - \mathrm{E}(a)\,\mathrm{E}(b)}$
- $\hat{y} = X \widehat{eta}$
- TSS = ESS + RSS

pel model)

Sum of Squares Total Sum of Squares (variabilitat de y)

$$\boldsymbol{TSS} = \sum_{i=1}^n (y_i - \overline{y})^2$$

 $ESS = \sum_{i=1}^{n} (\widehat{y}_i - \overline{y})^2$

$$i=1$$

ullet Explained Sum of Squares (variabilitat de y explicada

Residual Sum of Squares (variabilitat de y no explicada pel model):

» Propietats de vectors aleatoris $y=(y_1,\ldots,y_n)$ vector aleatori

$$RSS = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

	tor de constan matrius de cor			
Vector	Esperança (E)		Variància (V)
	/ E(m) \	$\int Var(y_1)$	$Cov(y_1, y_2)$	

Vector	Esperança (E)	Variància (∜)		
y	$\left(\begin{array}{c} \mathrm{E}(y_1) \ \\ \vdots \\ \mathrm{E}(y_n) \end{array}\right)'$	$ \begin{array}{c} \operatorname{Var}(y_1) \\ \operatorname{Cov}(y_2,y_1) \\ \vdots \\ \operatorname{Cov}(y_n,y_1) \end{array} $	$egin{aligned} \operatorname{Cov}(y_1,y_2) \ \operatorname{Var}(y_2) \ & dots \ \operatorname{Cov}(y_n,y_2) \end{aligned}$	•••
Ay + b	$A\cdot \mathbb{E}(y)+b$	$A \cdot \mathbb{V}(y) \cdot A^T$		