

1. Models de regressió lineal

1.1. Model general (mínims quadrats)

$$y = X\beta + \varepsilon$$

$$\begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} x_{11} & \dots & x_{1m} \\ \vdots & \ddots & \vdots \\ x_{n1} & \dots & x_{nm} \end{pmatrix} \begin{pmatrix} \alpha \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

- y : Vector de resposta
- X : Matriu de disseny
 - $x_{ij} \in \{0, 1\}$
 - $x_{i1} = 1$ (*intercept*)
- ε : Errors aleatoris (*i.i.d.*)
 - $\mathbb{E}(\varepsilon) = 0$
 - $\mathbb{V}(\varepsilon) = \sigma^2 I_n$

» Incògnites β ✓

Si $\text{Rang}(X) = m$:

$$\hat{\beta} = \boxed{(X^T X)^{-1} X^T y}$$

- $\mathbb{E}(\hat{\beta}) = \beta$
- $\mathbb{V}(\hat{\beta}) = \sigma^2 (X^T X)^{-1}$

» Variància de l'error σ^2 ✓

$$\hat{\sigma}^2 = \boxed{\frac{RSS}{n - m}}$$

1.2. Model clàssic

Tenim $\varepsilon \sim N(0, \sigma^2 I)$.

» Incògnites β ✓

Si $\text{Rang}(X) = m$:

$$l^T \hat{\beta} \sim N(l^T \beta, \sigma^2 l^T (X^T X)^{-1} l)$$

» Variància de l'error σ^2 ✓

Si $\text{Rang}(X) = m$:

$$\frac{RSS}{\sigma^2} \sim \chi_m^2$$

📖 Residus estandaritzats ✓

$$rst_i = \frac{r_i}{\hat{\sigma} \sqrt{1 - p_{ii}}} \sim N(0, 1)$$

- r_i element del residu $r = Y - \hat{Y} = (1 - P)Y$
- p_{ii} element de $P = X (X^T X)^{-1} X^T$

🖋️ Outliers ✓

$|rst_i| > 2 \implies$ potencial outlier

1.3. Model amb errors dependents

Tenim $\varepsilon_i = \rho \varepsilon_i + e_i$ amb ρ conegut tal que:

- $E(e_i) = 0$
- $\text{Var}(e_i) = \sigma^2$

Mètode ▾

Construir el nou model (clàssic):

$$y_i^* = \beta_0(1 - \rho) + \beta_1 x_i^* + e_i$$

$$\text{amb } \begin{cases} y_i^* = y_i - \rho y_{i-1} \\ x_i^* = x_i - \rho x_{i-1} \end{cases}$$

1.4. Model dels mínims quadrats generalitzat

Tenim $\text{Var}(\varepsilon) = \sigma^2 \Sigma = \sigma^2 P^2$ amb Σ conegut.

Mètode ▾

Construir el nou model (clàssic):

$$\begin{aligned} P^{-1}Y &= P^{-1}X\beta + P^{-1}\varepsilon \\ y^* &= X^*\beta + \varepsilon^* \end{aligned}$$

- $\hat{\beta} = (X^T \Sigma^{-1} X)^{-1} X^T \Sigma^{-1} y$

2. Bondat d'ajustament

Coeficient de determinació ▾

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS} \in (0, 1)$$

Coeficient de correlació ▾

V.A.s A, B amb mitjanes μ_A, μ_B i variàncies σ_A^2, σ_B^2

$$\rho_{AB} = \frac{\mathbb{E}((A - \mu_A)(B - \mu_B))}{\sigma_A \sigma_B} \in (-1, 1)$$

Coeficient de correlació mostral

Observacions a_1, \dots, a_n i b_1, \dots, b_n amb mitjanes mostrals \bar{a}, \bar{b} , i variàncies mostrals s_a^2, s_b^2

$$r_{AB} = \frac{\sum_{i=1}^n (a_i - \bar{a})(b_i - \bar{b})}{s_a s_b} \in (-1, 1)$$

3. Tests d'hipòtesis

» Test t generalitzat (1 coeficient) ▾

- Hipòtesis nul·la $H_0 : l^T \beta = 0$
- Estadístic de contrast
$$\mathbf{T} = \frac{\varphi^T y}{\hat{\sigma} \sqrt{\varphi^T \varphi}} \sim t_{n-m}$$
 amb
$$\varphi^T = l^T (X^T X)^{-1} X^T$$
- Rebutjem H_0 si $|T| > t_{1-\frac{\alpha}{2}, n-m}$

» Interval de confiança ▾

$$IC_{\alpha}(l^T \beta) = \left(l^T \hat{\beta} \pm t_{1-\frac{\alpha}{2}, n-m} \hat{\sigma} \sqrt{l^T (X^T X)^{-1} l} \right)$$

» Test F generalitzat (múltiples coeficients) ✓

- Hipòtesis nul·la $H_0 : L\beta = 0$
- Estadístic de contrast

$$F = \frac{(L\hat{\beta})^T (L(X^T X)^{-1} L^T)^{-1} (L\hat{\beta}) (n - m)}{q \cdot RSS} \sim F_{q, n-m}$$

amb q nombre de files de L

- Rebutjem H_0 si $F > F_{1-\alpha, q, n-m}$

4. Observacions influents

» Mesura de la influència ✓

Influència de l'element i -èssim en el model:

$$D_i = \frac{(\hat{\beta} - \hat{\beta}_{\bar{i}})^T X^T X (\hat{\beta} - \hat{\beta}_{\bar{i}})}{(p + 1) \hat{\sigma}^2}$$

- $\hat{\beta}_{\bar{i}}$: estimador de β sense la i -èssima observació

Interpretació de D ✓

Observació influent si:

- $D_i > 1$
- $D_i > \frac{4}{n}$

» Leverage ✓

Leverage de la observació i -èssima del model:

element p_{ii} de $P = X(X^T X)^{-1} X^T$

- $p_{ii} > \frac{2m}{n} \implies$ possible influència excessiva

5. Estabilització de la variància

Tenim V.A. X amb:

- $E(X) = \mu$
- $\text{Var}(X) = k h(\mu)$

Transformacions estabilitzants de variància ▾

Construir una nova V.A.:

$$Y = g(X)$$

- $\text{Var}(Y) \sim k h(\mu) g'(\mu)^2$ (constant)
- $g(\mu) = \int \frac{C}{\sqrt{h(\mu)}} d\mu$

Distribució	Variància	Transformació
Poisson	$\propto \mu$	$g(X) = \sqrt{X}$ (*)
Binomial	$\propto \mu(1 - \mu)$	$g(X) = \arcsin(\sqrt{X})$
Exponencial	$\propto \mu^2$	$g(X) = \ln(X)$
desconeguda (Box-Cox)	desconeguda	$g_\lambda(x_i) = \begin{cases} \frac{x_i^\lambda - 1}{\lambda} & \text{si } \lambda \neq 0 \\ \log(x_i) & \text{si } \lambda = 0 \end{cases}$

(*) Per n petita, podem fer servir $g(X) = \sqrt{X + \frac{3}{8}}$.

Apèndix

- Estimador $\hat{\alpha}$ **no esbiaixat** si $E(\hat{\alpha}) = \alpha$

- **Covariància** $\text{Cov}(a, b) = \boxed{\text{E}(ab) - \text{E}(a) \text{E}(b)}$
- $\hat{y} = X\hat{\beta}$
- $TSS = ESS + RSS$

Sum of Squares ▾

- **Total Sum of Squares** (variabilitat de y)

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2$$

- **Explained Sum of Squares** (variabilitat de y explicada pel model)

$$ESS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

- **Residual Sum of Squares** (variabilitat de y **no** explicada pel model):

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

» Propietats de vectors aleatoris ▾

- $y = (y_1, \dots, y_n)$ vector aleatori
- b vector de constants
- A, B matrius de constants

Vector	Esperança (\mathbb{E})	Variància (\mathbb{V})
y	$\begin{pmatrix} \text{E}(y_1) \\ \vdots \\ \text{E}(y_n) \end{pmatrix}$	$\begin{pmatrix} \text{Var}(y_1) & \text{Cov}(y_1, y_2) & \dots & \text{Cov}(y_1, y_n) \\ \text{Cov}(y_2, y_1) & \text{Var}(y_2) & \dots & \text{Cov}(y_2, y_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(y_n, y_1) & \text{Cov}(y_n, y_2) & \dots & \text{Var}(y_n) \end{pmatrix}$
$Ay + b$	$A \cdot \mathbb{E}(y) + b$	$A \cdot \mathbb{V}(y) \cdot A^T$

- $\text{Cov}(Ay, By) = A \cdot \mathbb{V}(y) \cdot B^T$